



Master Bioinformatique

[HAU701I|HAU904I] : Projet bibliographique

Estimer la vitesse de dispersion de pathogènes à partir de la comparaison de séquences génétiques géo-référencées

Auteur :
Rayane Ayoub
AIT ALLAOUA

Encadrement scientifique:
Stéphane GUINDON
Tuteur pédagogique :
Sylvain DAUDÉ

[Version du December 20, 2024| Version finale]

Table des matières

1	Préambule	2
2	Introduction	2
3	Principes de la modélisation en phylogéographie	6
4	Modèle de mouvement Brownien / Relaxed random Walk	7
4.1	Modèle de la diffusion Brownienne (BD)	7
4.2	Modèle de la Relaxed Random Walk (RRW)	7
4.3	Calcul de la vraisemblance	8
5	Modèle d'isolement par la distance IBD	9
5.1	Introduction	9
5.2	Modèle de Wright Fisher	9
5.3	Modèle du n -coalescent	10
5.4	Modèle du Coalescent Structuré	11
5.5	L'estimation de la vitesse par régression dans les modèles IBD	12
5.5.1	La distance entre individus	12
5.5.2	La distance entre les gènes	12
5.5.3	L'estimation de la vitesse	13
6	Les outils de simulation et d'inférence	14
6.1	BEAST	14
6.1.1	Introduction	14
6.1.2	Les entrées dans BEAST:	14
6.1.3	Les sorties de BEAST	15
6.2	GSpace	15
6.2.1	Introduction	15
6.2.2	Modèles de dispersion	15
6.2.3	Les entrées de GSpace	15
6.2.4	Les sorties de GSpace	15
7	Conclusion	16
8	Références	17
A	Annexe 1: exemple de document GSpaceSettings.txt	18

1 Préambule

Ce projet de recherche bibliographique est rédigé dans le cadre du master bio-informatique proposé par la Faculté des Sciences de l'Université de Montpellier. Il constitue une contribution préliminaire au projet de recherche proposé par M. Stéphane GUINDON sur lequel je travaillerai au printemps-été 2025.

Ce projet vise à comparer différents modèles probabilistes qui décrivent l'évolution de séquences génétiques homologues dans le temps et l'espace. Plus spécifiquement, nous nous intéressons ici à la comparaison des modèles décrivant de manière conjointe l'évolution moléculaire et la migration utilisé dans logiciel GSpace (Virgoulay, Rousset, and Leblois 2021b). Nous utiliserons ce dernier pour simuler des jeux de données, c'est à dire des séquences génétiques géo-référencées. Ces dernières seront ensuite analysées en utilisant le logiciel BEAST (Suchard et al. 2018) qui implémente le modèle Relaxed Random Walk (Lemey et al. 2010). Ces modèles reposent sur une modélisation simplifiée des processus de migration. Ils sont cependant associés à des techniques efficaces d'inférence bayésienne de leurs paramètres.

Dans ce rapport nous allons découvrir les modèles de génétique spatiale des populations et de phylogéographie. En commençant par les modèles browniens donc Brownian Diffusion (BD) et Relaxed Random Walk (RRW). Ensuite les modèles de Wright Fisher (WF) et du n -coalescent, très largement utilisés en génétique des populations. Les approches dérivant du modèle d'isolement par la distance proposés dans Wright 1943, Wright 1946 et Malécot 1948 seront introduits ensuite et nous nous attarderons sur le coalescent structuré. Enfin nous explorerons les deux principaux outils dont nous nous servirons pour la simulation des données (GSpace) et l'inférence des paramètres (BEAST).

2 Introduction

La phylogénie moléculaire est l'étude de l'histoire évolutive de la vie en utilisant des techniques de génomique. Les résultats de ces études sont représentés sous forme d'un arbre phylogénétique, enraciné ou non.

Les bases de cette science remontent au philosophe du XIVe siècle Guillaume d'Ockham et à son principe du Rasoir d'Ockham dans son livre *Summa totius logicae* (1323), autrement connu sous le nom de principe de parcimonie « *lex parsimoniae* » :

Pluralitas non est ponenda sine necessitate
(les multiples ne doivent pas être utilisés sans nécessité)

En se basant sur ces idées, les méthodes de Maximum Parsimony ont été

développées. Ce sont des méthodes statistiques non paramétriques d'inférence phylogénétique qui reconstruisent des arbres minimisant le nombre de changements des séquences au cours de leur évolution.

Ensuite, au XVIIIe siècle, les travaux de Pierre-Simon (Marquis de Laplace) sur sa première loi des erreurs, aussi connue sous le nom de « distribution de Laplace », ont été publiés. Ces derniers constitueront, deux siècles plus tard, les bases de la modélisation de l'évolution moléculaire comme un processus stochastique.

Au XIXe siècle, la phylogénie telle que nous la connaissons aujourd'hui a commencé à émerger avec « l'arbre de la vie » dessiné en 1837 dans un des carnets de Charles Darwin (Cambridge University Library), ainsi que les travaux du géologue américain Edward Hitchcock (1866).

Au XXe siècle, suite aux travaux de Ronald Fisher (1912) sur le principe du maximum de vraisemblance (MV), les tentatives d'utiliser ce critère pour la phylogénie ont rapidement suivi, notamment les travaux d'Edwards et Cavalli-Sforza dans les années 1960 sur les systèmes de groupes sanguins A_1A_2BO , Rho, MNSs, Fy et Di dans quatre populations : Eskimo, Bantu, Anglaise, Coréenne (Cavalli-Sforza and Edwards 1967).

Depuis, plusieurs autres modèles et méthodes d'inférence ont été développés et appliqués aux différents types de séquences (ADN, ARN, protéines).

Aujourd'hui, l'inférence phylogénétique s'appuie sur différentes techniques pour reconstruire l'histoire évolutive. Les plus utilisées à ce jour sont les méthodes de parcimonie, les méthodes basées sur l'estimation et l'analyse de distances évolutives entre paires de séquences homologues, le maximum de vraisemblance et l'inférence bayésienne.

Les résultats de ces études sont représentés sous forme d'arbres phylogénétiques binaires, similaires à des dendrogrammes¹. Les feuilles de l'arbre représentent notre échantillon, et chaque nœud interne est un ancêtre commun à un sous-ensemble de séquences de l'échantillon. En remontant l'arbre - et donc le temps évolutif - on peut arriver à l'ancêtre commun le plus récent de toutes les séquences de notre échantillon.

Toutes ces méthodes utilisent les informations sur les séquences (ADN, ARN ou protéines) pour retracer l'évolution des individus dans le temps. Cependant, en ajoutant des données sur la position géographique des échantillons, on peut également retracer l'évolution des lignées dans l'espace. La phylogéographie est la discipline dont l'objectif est de reconstruire les mouvements de dispersion spatiale des lignées au cours de l'évolution à partir de l'analyse

¹Un dendrogramme est un arbre binaire dont les nœuds sont les classes de la hiérarchie. Randriamihison, Neuvial, and Vialaneix 2019




Figure 1: Le croquis de 1837 de Charles Darwin, son premier diagramme d'un arbre évolutif, tiré de son premier carnet sur la transmutation des espèces (Darwin 1837).




Figure 2: Arbre phylogénétique
proposé par Haeckel (1866).

de séquences génétiques géo-référencées. Il s'agit d'un domaine interdisciplinaire liant la phylogénie et l'étude de l'évolution en observant les relations entre les séquences, ainsi que la géographie pour comprendre l'évolution spatiale et temporelle des lignées.

Ce type d'étude permet, par exemple, de reconstruire les mouvements et la dispersion de pathogènes tels que le West Nile Virus (WNV) étudié par Pybus et al. 2012. Cette analyse a révélé que la dissémination de ce pathogène en Amérique du Nord est caractérisée par des mouvements rapides et à longue distance, probablement attribués aux migrations des oiseaux et/ou au transport des hôtes infectés / vecteurs par l'activité humaine (fig. 3). Ces déplacements laissent une empreinte détectable par la phylogénie même lorsque ces événements sont trop rares pour être détectés par l'observation directe.

Une autre étude par Dellicour et al. 2018, suite à l'épidémie d'Ebola de 2013 en Afrique de l'Ouest, démontre la pertinence de la phylogéographie dans la gestion épidémiologique. L'épidémie a émergé en 2013 dans la préfecture




Figure 3: La diffusion temporo-spatiale reconstituée du WNV en Amérique du Nord, à partir de 1999 (A–H). Les cercles blancs marquent les sites d'échantillonnage, et les lignes noires projettent une phylogénie représentative, avec chaque nœud correspondant à un emplacement connu ou estimé. Les nuages colorés montrent l'incertitude statistique des emplacements des lignées (régions HPD à 95 %). Figure adaptée de Pybus et al. 2012

de Guéckédou en Guinée, puis le virus s'est dispersé dans les pays adjacents (Sierra Leone et Libéria). Contrairement au West Nile Virus évoqué précédemment, les mouvements à longue distance ne sont pas le principal contributeur à la dissémination du virus. Ce sont en effet les déplacements courts ≤ 200 km qui ont été les plus importants ici. Par ailleurs, les zones urbaines majeures ont été cruciales dans la dispersion du virus. La conclusion a donc été que la restriction des vols entre les pays concernés a été peu efficace, et que la meilleure stratégie aurait été la restriction simultanée du mouvement des lignées virales dans les capitales des pays touchés, ce qui

aurait permis une réduction estimée de la taille de l'épidémie à un tiers.

Actuellement, les modèles dont nous disposons pour décrire l'évolution des populations correspondent souvent à une simplification du processus biologique (les phénomènes d'hybridation et de transferts horizontaux sont souvent ignorés). Donc toute estimation des paramètres gouvernant ces modèles relève d'une approximation des véritables processus sous-jacents.

3 Principes de la modélisation en phylogéographie

Afin d'illustrer le but de notre projet, supposons un échantillon composé des séquences nommées S_1, S_2, S_3 . La figure 4 montre l'arbre phylogénétique construit pour représenter l'évolution des séquences dans le temps. Chaque séquence est associée à une position géographique — en deux dimensions dans notre cas — sous forme de coordonnées spatiales (x, y) , correspondant généralement à la latitude et à la longitude. Cette information permet d'estimer la diffusion dans l'espace.

La distribution a posteriori de cet échantillon est proportionnelle à la multiplication de trois probabilités : 1. En possédant les informations des séquences S : $P(S \mid \tau, t)$, avec τ représentant la topologie de l'arbre et t peut être exprimé en unités de temps calendaire lorsque l'horloge moléculaire est calibrée. Cette calibration est réalisable si le taux de mutation est connu ou si les séquences ont été collectées à des instants différents dans le temps.

2. En possédant les informations sur la position X et étant donnés les paramètres du modèle : $P(X \mid \tau, t, \sigma^2, \Phi)$, avec σ^2 la variance du modèle de diffusion spatiale et Φ un vecteur de paramètres de diffusion dont chaque valeur est associée à une branche de l'arbre (voir ci-dessous, modèle "Relaxed Random Walk").

3. La probabilité conjointe a priori des paramètres du modèle $P(\tau, t, \sigma^2, \Phi)$.

La probabilité a posteriori est donc :

$$P(\sigma^2, \tau, t, \Phi \mid S, X) \propto P(S \mid \tau, t) \times P(X \mid \tau, t, \sigma^2, \Phi) \times P(\tau, t, \sigma^2, \Phi)$$

avec $\propto$ exprimant la proportionnalité

Dans ce travail, nous cherchons à estimer les paramètres gouvernant la diffusion spatiale des lignées ancestrales, à savoir t et σ^2 , via différents modèles probabilistes permettant de décrire nos échantillons.




Figure 4: Arbre phylogénétique des séquences S_n couplées à leurs coordonnées (x_n, y_n)

4 Modèle de mouvement Brownien / Relaxed random Walk

4.1 Modèle de la diffusion Brownienne (BD)

La diffusion brownienne dans les modèles de phylogéographie modélise un mouvement aléatoire et continu à travers l'espace géographique dans un environnement homogène en espace et en temps. Cela signifie que le taux de mouvement (ou taux de diffusion) est constant à travers l'arbre phylogénétique. La diffusion brownienne est utile dans les cas où le mouvement est régulier, mais elle peut simplifier à l'excès des scénarios réels où les taux de diffusion varient selon les lignées ou au fil du temps (Lemey et al. 2010).

La diffusion brownienne suppose que le mouvement entre les nœuds dépend du hasard avec une variance progressant de manière linéaire en fonction du temps. La probabilité de la position d'une séquence $S_b(x_b, y_b)$, connaissant $S_a(x_a, y_a)$ et séparée par un temps t , suit une loi normale :

$$X_b \mid X_a \sim \mathcal{N}(X_a, \sigma^2 t)$$

Cette distribution repose sur des hypothèses d'homogénéité spatiale et temporelle : le même taux de diffusion s'applique à toutes les lignées, périodes et régions. Le processus repose donc sur une hypothèse d'isotropie et de continuité dans l'espace, impliquant un mouvement équiprobable dans toutes les directions, sans biais, dans un espace continu sans obstacle.

4.2 Modèle de la Relaxed Random Walk (RRW)

Tel que vous pouvez le constater, le modèle de la BD est plutôt simpliste face à la réalité biologique, où ni le temps, ni l'espace ne sont homogènes (si

seulement !). Cela a donné naissance au modèle de la RRW. Dans ce modèle, chaque branche de l'arbre dispose de son propre taux de diffusion, qui est un scalaire de taux Φ . Ces scalaires sont tirés d'une distribution log-normale ou Gamma γ . La variance de la loi normale décrivant la distribution à la fin d'une branche de longueur t est donnée par $\sigma^2 \times \Phi \times t$. Par conséquent, le déplacement de X_0 à X_1 est modélisé comme :

$$X_1 | X_0 \sim \mathcal{N}(X_0, \sigma^2 \times \Phi \times t_0)$$

Les lignées où la dispersion est rapide vont être associées à des valeurs de Φ élevées, tel est le cas de la lignée 2 de la figure 5, contrairement à celles où la diffusion est lente, qui correspondent à de petites valeurs de Φ , comme la lignée 1 de la même figure.

L'avantage du modèle RRW, contrairement au BD standard, est la modélisation plus réaliste des processus de dispersion hétérogènes dus à une multitude de facteurs (géographiques, comportementaux, ...), ainsi que la précision obtenue - et donc une réduction des zones d'incertitude (HPD, High Posterior Density) selon Lemey et al. 2010 - grâce à une meilleure adaptation aux données.




Figure 5: Arbre phylogénétique des séquences S_n couplées à leurs coordonnées (x_n, y_n) , les taux de dispersions Φ_n de chaque branche et une estimation de leurs valeurs.

4.3 Calcul de la vraisemblance

Le BD et le RRW décrivent ce qui se passe à l'échelle d'une branche. Les distributions de probabilités introduites ci-dessus permettent donc d'évaluer la

vraisemblance lorsque les données des nœuds internes de l'arbre sont connues (fig. 5). Cette vraisemblance est exprimée comme suit :

$$P(x_1, x_2, x_3, x_4, x_5) = P(x_5) \times P(x_1 | x_5) \times P(x_4 | x_5) \times P(x_2 | x_4) \times P(x_3 | x_4)$$

Il s'agit de la vraisemblance pour la position en une dimension (x), si les positions x et y sont indépendantes, la vraisemblance pour les positions en y peuvent être obtenue de manière analogue.

Cependant, il s'agit de la vraisemblance des données augmentées, c'est-à-dire en considérant que x_4 et x_5 sont connues. Or, en pratique, nous ne disposons pas d'informations sur ces lignées ancestrales. Ainsi, la vraisemblance non augmentée, évaluée à partir des données observées x_1 , x_2 et x_3 , intègre les coordonnées ancestrales :

$$P(x_1, x_2, x_3 | \tau, t, \sigma^2) = \iint P(x_1, x_2, x_3, x_4, x_5 | \tau, t, \sigma^2) \partial x_4 \partial x_5$$

Ces intégrales portant sur des produits de lois normales, une résolution analytique est possible (Hassler et al. 2022).

5 Modèle d'isolement par la distance IBD

5.1 Introduction

On a présenté l'approche RRW, qui est un modèle hiérarchique où la diffusion est décrite le long d'une phylogénie existante. Il existe d'autres modèles, plus sophistiqués, qui décrivent de manière conjointe les processus générant l'arbre phylogénétique et la diffusion spatiale.

Avant de présenter les modèles IBD, on donne une vue d'ensemble sur les modèles de Wright-Fisher et n-coalescent, qui sont des modèles classiques de génétique des populations sur lesquels s'appuient les modèles d'isolement par la distance.

5.2 Modèle de Wright Fisher

Le modèle de Wright-Fisher (WF) fait partie d'une classe de modèles couramment utilisés en génétique des populations. Il décrit l'évolution d'une population en avant dans le temps, partant d'une génération parentale G_0 de taille N constante et finie, dont les gènes sont passés indépendamment et avec la même probabilité. Les générations sont non-chevauchantes, ce qui signifie que la génération G_1 remplace entièrement la génération parentale G_0 . La taille finie de la population implique la disparition de certains gènes et/ou la fixation d'autres, entraînant ainsi une perte de la diversité génétique.

Posons A et a comme deux allèles. i représente le nombre de copies de A et $N - i$ est le nombre de copies de a dans la population à la génération G_0 . Ainsi, la fréquence de A est $p = i/N$, et la fréquence de a est $1 - p$. La probabilité que le gène A ayant i copies à G_0 soit trouvé à j copies dans la génération G_1 suit une loi binomiale de paramètres p et N :

$$P_{ij} = \binom{N}{j} p^j (1 - p)^{N-j} \quad 0 \leq j \leq N$$

Le nombre de copies de A à la génération G_1 peut donc prendre des valeurs de 0 à N et donc peut potentiellement disparaître (cas $j = 0$) ou être fixé (si $j = N$). Cette variation du nombre de copies de A décrit la dérive génétique (Leblois 2004).

5.3 Modèle du n -coalescent

La coalescence, du latin “coalescere” signifiant l’union de parties auparavant séparées, se définit dans notre contexte par l’union des individus de la population du modèle de Wright-Fisher (WF) à la génération G_n , qui se rejoignent au niveau des nœuds représentant les ancêtres communs les plus récents (MRCA) à la génération G_{n-1} . Dans un échantillon de taille k , le nombre d’individus diminue de k à $k - 1$, puis à $k - 2$, et ainsi de suite au cours des générations, jusqu’à atteindre l’ancêtre commun le plus récent (MRCA).

En se basant sur le modèle de Wright-Fisher, on peut déduire que dans une population panmictique de taille N , avec des générations non chevauchantes, la probabilité de coalescence C de deux lignées à la génération précédente est de $P = 1/N$. Par conséquent, la probabilité qu’une coalescence n’ait pas lieu est de $P = 1 - (1/N)$. Puisque les générations sont indépendantes, la probabilité de non-coalescence après t générations est donnée par $P^t = (1 - 1/N)^t$. La probabilité d’une coalescence à t générations suit donc une loi géométrique :

$$P(C = i|N) = \frac{1}{N} \times \left(1 - \frac{1}{N}\right)^{i-1}$$

Lorsque l’unité de temps est mise à l’échelle de manière à ce que i générations correspondent à Nk unités du nouveau temps, on a

$$P(C > kN|N) = \left(1 - \frac{1}{N}\right)^{kN}$$

Lorsque $N \rightarrow \infty$, on a donc $P(C' > k) = \exp(-k)$, où C' correspond au temps mis à l’échelle. La distribution du temps de coalescence est donc exponentielle.

Un processus suivant WF en avant dans le temps peut être décrit suivant le n -coalescent en arrière dans le temps. Cependant cette dualité n’est pas

limitée qu'au WF, il existe aussi d'autres modèles généalogiques tel que le modèle de Moran qui présentent cette caractéristique. Ce dernier décrit une population à générations chevauchantes (contrairement à WF), dans laquelle à chaque étape discrète de temps un individu se reproduit et un autre disparaît, maintenant ainsi la taille de la population constante. Ceci implique une dérive génétique moins importante, mais une vitesse de coalescence plus importante que le WF. Le modèle du coalescent est donc une bonne approximation du processus stochastique générant la généalogie d'un échantillon d'individus issus d'une population évoluant suivant un modèle biologique réaliste, bien que simplifié.




Figure 6: Représentation d'une population $N = 7$ suivant le modèle Wright-Fisher. L'évènement de coalescence est représenté en vert.

5.4 Modèle du Coalescent Structuré

Le modèle du n -coalescent abordé précédemment s'applique à une population panmictique, tandis que le modèle du Structured Coalescent considère une population d'individus N_{totale} subdivisée en n_d sous-populations de tailles N_i , telles que la somme $\sum_i^{n_d} N_i = N_{\text{totale}}$. Chacune de ces sous-populations est panmictique et forme un dème. Cette structure, plus proche de la réalité biologique que le modèle de Wright-Fisher, présente un phénomène intéressant : la migration entre dèmes, notée b_{ij} , ou migration "arrière". Autrement dit, b_{ij} représente la probabilité qu'un individu du dème i ait pour parent

un individu du dème j .

On considère que quand $N_{\text{totale}} \rightarrow \infty$, les probabilités que plusieurs événements de migration et/ou de coalescence aient lieu en une seule génération sont négligeables. Cela veut dire que les seuls événements possibles sont la coalescence au sein d'un dème ou la migration entre deux dèmes.

On prend N_i le nombre d'individus du dème i . Le temps attendu pour qu'un événement se produise suit une loi exponentielle de moyenne r , le taux global d'événements :

$$r(\mathbf{n}) = \sum_i \frac{k_i(k_i-1)}{2N_i} + \sum_{j \neq i} k_i b_{ij}$$

où k_i le nombre de lignées de notre échantillon, présentes au sein du dème i au temps considéré.

Si un événement a lieu, il s'agit soit d'une coalescence dans le dème i avec une probabilité

$$P = \frac{k_i(k_i-1)/2N_i}{r(\mathbf{n})}$$

où d'une migration arrière du dème i vers j avec

$$P = \frac{k_i b_{ij}}{r(\mathbf{n})}$$

Le modèle du coalescent structuré simplifié décrit des probabilités de migrations entre dèmes b_{ij} égales. Cependant, l'isolement par la distance nous permet aussi de décrire des cas où la probabilité de migration b_{ij} varie en fonction de la distance entre dèmes (b_{ij} est plus importante entre les dèmes les plus proches).

5.5 L'estimation de la vitesse par régression dans les modèles IBD

Une méthode simple pour estimer la vitesse de migration est basée sur l'observation des distances génétiques et géographiques entre les individus. Ainsi, la vitesse de dispersion est décrite par la droite de régression entre ces distances.

5.5.1 La distance entre individus

Comme vu précédemment, la position est décrite en coordonnées (x, y) . À partir de cela, nous définissons la distance comme étant la distance euclidienne $r \equiv \sqrt{x^2 + y^2}$ selon Rousset 2004.

5.5.2 La distance entre les gènes

Un paramètre important est F_{ST} , qui représente la relation entre les gènes du même dème et ceux des autres dèmes. F_{ST} représente la proportion de




Figure 7: Représentation d’une population en 3 dèmes (chacun associé à une couleur) à taille $N = 7$ au cours de 3 générations (rectangle pointillé). Un évènement de migration a lieu au sein de G_1 . L’évolution de la population en “avant” dans le temps est représenté par l’axe du temps (t) permettant le passage entre génération. Le coalescent en “arrière” dans le temps est représentée en vert.

variation génétique totale qui est due à des différences entre sous-populations. Une valeur élevée (F_{ST} proche de 1) indique une forte différenciation, tandis qu’une valeur faible (F_{ST} proche de 0) indique que les sous-populations sont génétiquement similaires. Q_1 représente l’identité des gènes au sein du même dème, Q_2 représente l’identité des gènes entre les différents dèmes. Le F_{ST} défini dans Wright 1951 et Wright 1969 est :

$$F_{ST} = \frac{Q_1 - Q_2}{1 - Q_2}$$

5.5.3 L’estimation de la vitesse

Lorsqu’on relie F_{ST} à une distance physique d , on modélise l’isolement par la distance, c’est-à-dire comment les gènes se différencient en fonction de la distance géographique à cause de la dispersion limitée.

En une dimension (habitat linéaire), on remarque une relation linéaire entre F_{ST} et d : $F_{ST} \propto d$.

En deux dimensions (habitat bidimensionnel), on observe une relation logarithmique : $F_{ST} \propto \log d$.

Le coefficient de régression entre F_{ST} et d est lié à σ^2 , la variance des dis-

tances de dispersion qui mesure la distance moyenne parcourue par les gènes en une génération. En utilisant les équations du modèle de lattice donné par Rousset 2004, et si l’horloge moléculaire est calibrée, on peut estimer σ^2 et en déduire la vitesse moyenne de dispersion des gènes dans l’espace.

Cependant, cette approche présente des difficultés, notamment les constantes A_1 et A_2 (Rousset 2004, équations 3.40 et 3.43), qui dépendent de la distribution de la dispersion. Les valeurs de A_1 et A_2 sont aussi étroitement liées à la taille et à la structure de la population. Cela rend leur estimation difficile dans la réalité où les populations ne suivent pas exactement les modèles proposés. Cette incertitude des constantes diminue la précision de l’estimation de σ^2 par régression. Ainsi, les estimations de σ^2 peuvent être biaisées ou avoir de larges intervalles de confiance, rendant l’interprétation des résultats incertaine.

6 Les outils de simulation et d’inférence

Dans les chapitres précédents, nous avons présenté les principaux modèles en phylogéographie. Nous présentons maintenant les différents outils permettant d’effectuer l’inférence des paramètres de ces modèles à partir d’alignements de séquences dotées de coordonnées spatiales.

6.1 BEAST

6.1.1 Introduction

BEAST (Bayesian Evolutionary Analysis Sampling Trees) est un logiciel conçu pour les analyses phylogénétiques. Il est orienté vers l’analyse des phylogénies dans le temps inféré avec une horloge moléculaire stricte ou relâchée, c’est-à-dire permettant aux vitesses d’évolution moléculaire de varier dans le temps et entre lignées. Cet outil permet d’inférer les paramètres de la population suivant le modèle RRW vu précédemment.

Il permet de reconstruire les phylogénies ainsi que tester les hypothèses évolutives. BEAST utilise la technique de construction de chaînes de Markov par Monte Carlo (MCMC) pour moyenner sur l’ensemble des arbres permettant la pondération proportionnelle à la probabilité a posteriori pour chaque arbre (Suchard et al. 2018). Ce logiciel nous permettra donc d’effectuer une inférence sur les paramètres gouvernant notre population, suivant un modèle Relaxed Random Walk (4.2).

6.1.2 Les entrées dans BEAST:

BEAST prend des fichiers XML comme entrées. Ces fichiers sont générés en utilisant l’outil BEAUti qui permet d’importer un alignement en format

NEXUS, les préférences sur le modèle et générer le fichier XML. Ce fichier XML est ensuite utilisé pour lancer BEAST (BEAST-Developers 2024a).

6.1.3 Les sorties de BEAST

Suite à l'analyse, ce logiciel génère des fichiers .log contenant les valeurs des paramètres échantillonnées par MCMC. Ces résultats sont analysés par la suite en utilisant l'outil Tracer.

On obtient aussi un arbre consensus. Cet arbre est obtenu en construisant un arbre MCC (Maximum Clade Credibility) via l'outil TreeAnnotator. Ces arbres peuvent être visualisés en utilisant le logiciel FigTree.

Un fichier "State File" .stat est généré enregistrant l'état actuel de la MCMC (BEAST-Developers 2024b).

6.2 GSpace

6.2.1 Introduction

GSpace est un programme qui permet de simuler des données génomiques neutres suivant plusieurs modèles démographiques, notamment le modèle du coalescent structuré vu précédemment. Il est basé sur une approche de génération en génération (gen-by-gen) couplé à un algorithme de recombinaison et des modèles flexibles de dispersion et des tailles de sous-populations.

6.2.2 Modèles de dispersion

La dispersion des individus dans la nature n'est pas homogène - tel que décrit précédemment dans le modèle BD - mais plutôt influencé par plusieurs facteurs. Pour simuler cela, GSpace représente une matrice de sous-populations composée d'au moins un individu suivant différents modèles de distribution.

6.2.3 Les entrées de GSpace

GSpace prend comme entrée un fichier .txt simple (ASCII) au nom par défaut "*GSpaceSettings.txt*" précisant les paramètres de chaque lancement. Les lignes du fichier sont sous forme **keyword=value** ou **keyword=value1,value2,value3**. L'annexe A est un exemple complet d'un fichier GSpaceSettings.txt.

6.2.4 Les sorties de GSpace

Les sorties de GSpace sont:

1. Les jeux de données simulés au format sélectionné (Genepop v.4, VCF, fasta, phylip ou tree sequence).

Distribution	Motif de la distribution	Exemple
Uniforme	Probabilité égale de mouvement dans un intervalle donné	Graines dispersées par le vent dans un rayon limité
Géométrique	Forte probabilité de courts déplacements, faible pour longs	Animaux lents comme les escargots
Gaussienne	Plus forte probabilité autour d'une distance centrale, décroît symétriquement	Rongeurs cherchant autour de leur terrier
Fat-tailed	Forte probabilité de courts déplacements, rares longs déplacements	Oiseaux avec des migrations rares
Stepping-stone	Mouvement seulement vers des sous-populations adjacentes	Grenouilles dans une série d'étangs
Island	Probabilité égale de mouvement entre toutes les sous-populations	Oiseaux sur des îles équidistantes

Table 1: Tableau récapitulatif des modèles de distribution dans GSpace. adapté de Virgoulay, Rousset, and Leblois 2021a

2. Un fichier texte contenant les coordonnées de chaque individu.
3. Un fichier texte contenant les informations sur chaque haplotype simulé.
4. Un fichier résumant les paramètres de la simulation ainsi que quelques statistiques de la distribution de dispersion.
5. Un fichier des statistiques génétiques par simulation
6. Un fichier des statistiques par chromosome, et un autre par locus.
7. Un fichier contenant La distribution empirique de la dispersion effective calculée à partir de tous les événements de dispersion survenus pendant les simulations.

7 Conclusion

Après cette introduction aux principaux modèles de la phylogéographie et aux outils utilisés pour la simulation et l'inférence dans ce projet bibliographique, nous passons à la seconde étape du projet, un stage prévu de mai à août 2025 au sein du Laboratoire d'Informatique, de Robotique et de Microélectronique de Montpellier (LIRMM). Au cours de ce stage, nous visons à estimer les vitesses de dispersion des données simulées par GSpace. Nous effectuerons ces estimations en appliquant la méthode de régression ainsi qu'en utilisant BEAST pour les méthodes basées sur la RRW afin de comparer ces deux approches du point de vue de leur aptitude à estimer les vitesses de diffusion.

8 Références

- BEAST-Developers (2024a). *First Tutorial*. Accessed: December 8, 2024. URL: https://beast.community/first_tutorial.
- (2024b). *Second Tutorial*. Accessed: December 8, 2024. URL: https://beast.community/second_tutorial.
- Cavalli-Sforza, L. L. and A. W. Edwards (1967). “Phylogenetic analysis. Models and estimation procedures”. In: *Am. J. Hum. Genet.* 19.3 Pt 1, pp. 233–257.
- Darwin, C. (1837). *Transmutation of species*. <http://cudl.lib.cam.ac.uk/view/MS-DAR-00121/38>.
- Dellicour, S. et al. (2018). “Phyldynamic assessment of intervention strategies for the West African Ebola virus outbreak”. In: *Nat. Commun.* 9. DOI: 10.1038/s41467-018-03763-2.
- Hassler, G. et al. (2022). “Inferring phenotypic trait evolution on large trees with many incomplete measurements”. In: *J. Am. Stat. Assoc.* 117.538, pp. 678–692.
- Leblois, R. (2004). *Inférence en génétique spatiale des populations vue par le prisme de la coalescence*. Université de Montpellier.
- Lemey, P. et al. (2010). “Phylogeography Takes a Relaxed Random Walk in Continuous Space and Time”. In: *Mol. Biol. Evol.* 27, pp. 1877–1885. DOI: 10.1093/molbev/msq074.
- Malécot, G. (1948). “Les mathématiques de l’hérédité”. In: *Paris: Masson*.
- Pybus, O. G. et al. (2012). “Unifying the spatial epidemiology and molecular evolution of emerging epidemics”. In: *Proc. Natl. Acad. Sci.* 109.37, pp. 15066–15071. DOI: 10.1073/pnas.1206598109.
- Randriamihamison, N., P. Neuvial, and N. Vialaneix (2019). “Classification ascendante hiérarchique, contrainte d’ordre: conditions d’applicabilité, interprétabilité des dendrogrammes”. In: *Institut de Mathématiques de Toulouse*.
- Rousset, F. (2004). *Genetic Structure and Selection in Subdivided Populations*. Princeton University Press.
- Suchard, M. A. et al. (2018). “Bayesian phylogenetic and phylodynamic data integration using BEAST 1.10”. In: *Virus Evol.* 4.1, vey016. DOI: 10.1093/ve/vey016.
- Virgoulay, T., F. Rousset, and R. Leblois (2021a). *GSpace version 1.0 User Manual*. https://github.com/ThimothéeV/GSpace/blob/main/GSpace_User_Guide.pdf.
- (2021b). “GSpace: an exact coalescence simulator of recombining genomes under isolation by distance”. In: *Bioinformatics* 37.20, pp. 3673–3675. DOI: 10.1093/bioinformatics/btab261.
- Wright, S. (1943). “Isolation by distance”. In: *Genetics*.
- (1946). “Isolation by distance under diverse systems of mating”. In: *Genetics*.
- (1951). “The genetical structure of populations”. In: *Annals of Eugenics*.

Wright, S. (1969). “Evolution and the genetics of populations. II. The theory of gene frequencies”. In: *University of Chicago Press*.

A Annexe 1: exemple de document GSpaceSettings.txt

GSpaceSettings.txt

```
%%%%%%%%% SIMULATION SETTINGS %%%%%%%%%%
Setting_Filename = GSpaceSettings.txt
Random_Seeds = 5
Run_Number = 2
%%%%%%%%% OUTPUT FILE FORMAT SETTINGS %%%%%%%%%%
Output_Dir = .
Data_File_Name = ContPop
Data_File_Extension = .txt
Genepop = True
Genepop_Ind_File = False
Genepop_Group_All_Samples = No
Genepop_No_Coord = F
VCF = No
Coord_File = N
Sequence_Characteristics_File = False
Fasta = N
Fasta_Single_Line_Seq = No
Phylip = N
Tskit = False
Approximate_time = False
%%%%%%%%% MARKERS SETTINGS %%%%%%%%%%
Ploidy = Haploid
Chromosome_number = 5
Mutation_Rate = 0.0005
Mutation_Model = SMM
Allelic_Lower_Bound = 1
Allelic_Upper_Bound = 200
Sequence_Length = 100
%%%%%%%%% RECOMBINATION SETTINGS %%%%%%%%%%
Recombination_Rate = 0.0005
%%%%%%%%% DEMOGRAPHIC SETTINGS %%%%%%%%%%
%% LATTICE
Node_Size_Matrix = No
Lattice_Size_X = 500
```

```

Lattice_Size_Y = 500
Ind_Per_Node = 1
%% DISPERSAL
Migration_Matrix = No
Dispersal_Distribution = g
Geometric_Shape = 0.2
Edge_Effects = circular
Total_Emigration_Rate = 0.2
Disp_Dist_Max = 100,100
%%%%%%%% SAMPLE SETTINGS %%%%%%%%%%
Sample_Size_X = 15
Sample_Size_Y = 15
Min_Sample_Coord_X = 200
Min_Sample_Coord_Y = 200
Void_Sample_Node_X = 1
Void_Sample_Node_Y = 1
Ind_Per_Node_Sampled = 1
%%%%%%%% VARIOUS COMPUTATION OPTION S%%%%%%%%%
%The code below can be specified in a single line %
Diagnostic_Tables = Prob_Id_2Loc, Prob_Id_1Loc,
Effective_Dispersal, Iterative, Per_Loc, Per_Chrom
Dist_Class_Nbr = 25

```