



Master Bioinformatique

[HAU805I] : Stage M1

Estimer la vitesse de dispersion de pathogènes à partir de la comparaison de séquences génétiques géo-référencées

Auteur :
Rayane Ayoub
AIT ALLAOUA

Encadrement scientifique:
Stéphane GUINDON
Tuteur pédagogique :
Sylvain DAUDÉ

Retrouvez les ressources associées à ce projet sur [GitHub](#)

Contents

1	Préambule	3
2	Introduction	4
3	Matériels et méthodes	6
3.1	Modèles	6
3.1.1	Modèle Isolation By Distance (IBD)	6
3.1.1.1	Principes théoriques du modèle	6
3.1.1.2	Simulation de données génétiques sous modèle IBD avec GSpace	7
3.1.2	Modèle Brownian Diffusion (BD)	9
3.1.2.1	Diffusion Brownienne (BD)	9
3.1.2.2	Relaxed Random Walk (RRW)	9
3.1.3	Récapitulatif	10
3.2	Méthodes d'inférence	11
3.2.1	Inférence bayésienne sous modèle RRW avec BEAST	11
3.2.1.1	Paramètres du modèle phylogénétique	11
3.2.2	Méthode de régression sous le modèle IBD	12
3.2.2.1	Implémentation du IBD via genepop	13
3.2.3	L'estimation par le modèle BD non-phylogénétique (approche analytique)	13
3.2.4	La méthode de régression par BD non-phylogénétique	15
3.3	Expériences	17
3.4	Objectifs de l'étude	17
3.4.1	Effet du rayon d'échantillonnage sur les taux de diffusion	17
3.4.1.1	Effet de la zone échantillonnée	18
3.4.1.2	Effet du nombre d'individus échantillonnés	18
3.4.2	Effet de la distance maximale de dispersion	18
3.5	Analyse statistique	19
4	Résultats	19
4.1	Effet du rayon d'échantillonnage	19
4.1.1	Modèle: RRW Méthode: BEAST	19
4.1.2	Modèle: BD Méthode: Analytique	20
4.1.3	Modèle: BD Méthode: Régression	21
4.1.4	Modèle: IBD Méthode: Régression	22
4.1.5	Résumé comparatif	23
4.2	Effet de la distance maximale de dispersion	23
4.2.1	Modèle: RRW Méthode: BEAST	24
4.2.2	Modèle: BD Méthode: Analytique	24
4.2.3	Modèle: BD Méthode: Régression	25
4.2.4	Modèle: IBD Méthode: Régression	26

4.2.4.1	L'intervalle de précision de la régression suivant le modèle IBD	27
4.2.5	Résumé comparatif	28
5	Discussion	29
6	Références	31
7	Annexe	32

1 Préambule

Ce projet constitue la phase applicative du travail bibliographique entamé à la fin de l'année 2024 (AIT ALLAOUA 2024). Il s'inscrit dans le cadre du master Bioinformatique proposé par la Faculté des Sciences de l'Université de Montpellier, et contribue à un projet de recherche encadré par M. Stéphane Guindon (CNRS, LIRMM).

Nous cherchons à comparer différents modèles probabilistes décrivant l'évolution conjointe des séquences génétiques dans le temps et dans l'espace. Deux cadres de modélisation sont au cœur de cette étude : (i) le modèle *Isolation By Distance* (IBD) , introduit par Sewall Wright (Wright 1943) et Gustave Malécot (Malécot 1948) dans les années 1930–1940, qui formalise le lien entre la similarité génétique et la distance géographique entre individus ; (ii) le modèle de diffusion brownienne (BD) et son extension, le *Relaxed Random Walk* (RRW) (Lemey et al. 2010), qui décrit la dispersion spatiale des lignées au cours de leur histoire évolutive.

L'estimation des paramètres associés à ces modèles repose sur trois approches principales :

- l'inférence bayésienne, appliquée au modèle RRW, qui permet d'estimer conjointement la phylogénie et les paramètres de dispersion ;
- la régression linéaire, utilisée pour relier distances génétiques et distances géographiques dans le cadre des modèles IBD et BD ;
- des méthodes analytiques non phylogénétiques basées sur la variance spatiale (BD non-phylogénétique), offrant une représentation simplifiée du processus de dispersion en ne s'appuyant pas sur la phylogénie.

Le modèle IBD est de nature *mécaniste* : il s'appuie sur les principes fondamentaux du phénomène biologique de dispersion pour décrire la relation entre structure génétique et distance géographique. Cependant, il se prête moins bien à l'application des méthodes d'inférence phylogéographique les plus avancées. À l'inverse, les modèles BD et RRW sont davantage *phénoménologiques* : ils ne cherchent pas à reproduire fidèlement les mécanismes biologiques sous-jacents, mais offrent une flexibilité et une adaptabilité qui les rendent particulièrement compatibles avec les approches d'inférence statistique sophistiquées.

Dans le contexte de la génétique des populations, le paramètre de dispersion σ^2 quantifie la vitesse moyenne avec laquelle les lignées génétiques se déplacent dans l'espace au fil des générations. Ce paramètre est central pour comprendre la dynamique spatiale des pathogènes, en particulier leur vitesse de diffusion. L'objectif principal de ce travail est d'évaluer la fiabilité

et la précision des estimations de σ^2 obtenues avec ces différentes approches, lorsque les données sont simulées sous un modèle IBD puis analysées selon une méthode native à l'IBD, une autre fondée sur le RRW (BD phylogénétique) ainsi que des approches analytiques non phylogénétiques.

Un objectif complémentaire est d'examiner l'impact des schémas d'échantillonnage spatial sur la précision des estimations de σ^2 . Pour ce faire, nous avons fait varier plusieurs paramètres clés de l'échantillonnage et observé les tendances des estimations produites par chaque méthode.

2 Introduction

La phylogénie moléculaire est l'étude de l'histoire évolutive de la vie en utilisant des techniques de génomique. Les bases de cette discipline remontent au XIXe suite aux travaux de Charles Darwin (Cambridge University Library), ainsi que les travaux du géologue américain Edward Hitchcock (1866). Au XXe siècle, le statisticien Ronald Fisher (1912) développe le principe du maximum de vraisemblance. Ce critère est utilisé pour la phylogénie, notamment à travers les travaux d'Edwards et Cavalli-Sforza dans les années 1960 sur les systèmes de groupes sanguins chez l'homme (Cavalli-Sforza and Edwards 1967).

Toutes ces méthodes utilisent les informations sur les séquences (ADN, ARN ou protéines) pour retracer l'évolution des individus dans le temps. Cependant, en ajoutant des données sur la position géographique des échantillons, on peut également retracer l'évolution des lignées dans l'espace. La phylogéographie est la discipline dont l'objectif est de reconstruire les mouvements de dispersion spatiale des lignées au cours de l'évolution à partir de l'analyse de séquences génétiques géo-référencées. Il s'agit d'un domaine interdisciplinaire liant la phylogénie et l'étude de l'évolution en observant les relations entre les séquences, ainsi que la géographie pour comprendre l'évolution spatiale et temporelle des lignées.

Ce type d'étude permet, par exemple, de reconstruire les mouvements et la dispersion de pathogènes tels que le West Nile Virus (WNV) étudiés par Pybus et al. 2012. Cette analyse a révélé que la dissémination de ce pathogène en Amérique du Nord est caractérisée par des mouvements rapides et à longue distance, probablement attribués aux migrations des oiseaux et/ou au transport des hôtes infectés/vecteurs par l'activité humaine (fig. 1). Ces déplacements laissent une empreinte détectable par la phylogénie même lorsque ces événements sont trop rares pour être détectés par l'observation directe.




Figure 1: La diffusion temporo-spatiale reconstituée du WNV en Amérique du Nord, à partir de 1999 (A–H). Les cercles blancs marquent les sites d'échantillonnage, et les lignes noires projettent une phylogénie représentative, avec chaque nœud correspondant à un emplacement connu ou estimé. Les nuages colorés montrent l'incertitude statistique des emplacements des lignées (régions HPD à 95 %). Figure adaptée de Pybus et al. 2012

Une autre étude par Dellicour et al. 2018, suite à l'épidémie d'Ebola de 2013 en Afrique de l'Ouest, démontre la pertinence de la phylogéographie dans la gestion épidémiologique. L'épidémie a émergé en 2013 dans la préfecture de Guéckédou en Guinée, puis le virus s'est dispersé dans les pays adjacents (Sierra Leone et Libéria). Contrairement au West Nile Virus évoqué précédemment, les mouvements à longue distance ne sont pas le principal contributeur à la dissémination du virus. Ce sont en effet les déplacements courts ≤ 200 km qui ont été les plus importants ici. Par ailleurs, les zones urbaines majeures ont été cruciales dans la dispersion du virus. La conclu-

sion a donc été que la restriction des vols entre les pays concernés a été peu efficace, et que la meilleure stratégie aurait été la restriction simultanée du mouvement des lignées virales dans les capitales des pays touchés, ce qui aurait permis une réduction estimée de la taille de l'épidémie à un tiers.

Actuellement, les modèles dont nous disposons pour décrire l'évolution des populations correspondent souvent à une simplification du processus biologique (les phénomènes d'hybridation et de transferts horizontaux sont souvent ignorés). Donc toute estimation des paramètres gouvernant ces modèles relèvent d'une approximation des véritables processus sous-jacents.

3 Matériels et méthodes

3.1 Modèles

3.1.1 Modèle Isolation By Distance (IBD)

3.1.1.1 Principes théoriques du modèle

Le modèle *Isolation By Distance* (IBD) est un cadre conceptuel et mathématique en génétique des populations qui décrit comment la similarité génétique entre individus décroît avec la distance géographique qui les sépare (Wright 1943; Malécot 1948). Il repose sur l'idée que la reproduction et les échanges génétiques se produisent plus fréquemment entre individus proches géographiquement que distants, ce qui génère une structuration spatiale des génotypes (Rousset 1999; Rousset 2004).

Dans sa formulation classique, la population est répartie dans un espace discret, souvent représenté par une grille de sous-populations (*dèmes*). À chaque génération :

1. Les individus se reproduisent localement, selon un modèle génétique défini.
2. Une partie de la descendance migre vers d'autres dèmes, avec une probabilité qui diminue en fonction de la distance.
3. Ce processus, répété sur de nombreuses générations, entraîne une corrélation négative entre distance géographique et similarité génétique. C'est-à-dire plus les individus sont séparés physiquement, moins ils seront similaires génétiquement.

Dans le cas des pathogènes, qui sont haploïdes, la reproduction ne nécessite qu'un seul génome parental. Cette particularité simplifie la modélisation et l'analyse, car il n'est pas nécessaire de représenter la combinaison de deux génomes parentaux comme chez les diploïdes.

3.1.1.2 Simulation de données génétiques sous modèle IBD avec GSpace

Dans ce travail, les données sont générées avec le logiciel **GSpace** (Virgoulay, Rousset, and Leblois 2021), qui implémente un modèle *Isolation By Distance* exact par coalescence, avec migration et mutations. L'algorithme opère **en remontant le temps** (*backward-in-time*) génération par génération, jusqu'au plus récent ancêtre commun (MRCA), avant de redescendre dans le temps pour simuler les mutations sur l'arbre obtenu.

La population est représentée par une grille bidimensionnelle de *dèmes* (sous-populations), chacun contenant un nombre fixe d'individus haploïdes.

Le modèle IBD est classiquement décrit à l'échelle d'une *population entière*, en représentant la structuration spatiale et les flux de gènes entre sous-populations. Dans le cadre de ce travail, il est appliqué à l'échelle de **l'échantillon analysé**, c'est-à-dire que la simulation décrit explicitement le processus évolutif subi par les individus de l'échantillon, tout en respectant les dynamiques attendues du modèle à grande échelle.

La simulation suit les étapes suivantes (fig. 2) :

1. **Initialisation ($G = 0$)** : Les individus échantillonnés occupent des positions définies sur la grille.
2. **Remontée dans le temps** :
 - (a) *Migration* : À chaque génération, chaque lignée peut migrer vers un autre dème selon une distribution de dispersion **Dispersal-Distribution**, bornée par **Disp_Dist_Max**. Les migrations sont représentées par des flèches rouges dans le schéma.
 - (b) *Coalescence* : Si deux lignées se retrouvent dans le même dème, elles peuvent coalescer (fusionner) en un ancêtre commun avec une probabilité dépendant de la taille locale du dème (**Ind_Per_Pop**). Les coalescences sont représentées par des flèches vertes.
 - (c) Ce processus migration-coalescence se répète génération après génération ($G = -1, -2, \dots$) jusqu'à ce que toutes les lignées aient convergé vers le MRCA. L'ensemble des relations ancestrales forme un arbre de coalescence.
3. **Descente dans le temps** :
 - (a) À partir du MRCA, des mutations sont ajoutées le long des branches selon le modèle de mutation choisi (**Mutation_Model** : HKY) et un taux **Mutation_Rate** fixe.

- (b) Le génome du MRCA peut être défini par l'utilisateur (MRCA-Sequence) ou généré aléatoirement.
4. **Génération des séquences simulées** : Les séquences obtenues pour les individus échantillonnés sont exportées aux formats choisis.




Figure 2: **Illustration du fonctionnement de GSpace**: En remontant le temps génération par génération ($G = 0$ à $G = -2$), les individus migrent sur la grille de l'habitat (flèches rouges) puis coalescent lorsqu'ils partagent un ancêtre commun (flèches vertes) jusqu'au MRCA. Cette information permet la reconstruction de l'arbre généalogique, à partir duquel des séquences sont simulées.

3.1.2 Modèle Brownian Diffusion (BD)

3.1.2.1 Diffusion Brownienne (BD)

En phylogéographie, la diffusion brownienne modélise le déplacement des lignées comme un mouvement aléatoire et continu dans un espace homogène en temps et en géographie. Le taux de diffusion est constant sur l'ensemble de l'arbre phylogénétique (fig. 3), impliquant une variance croissante linéairement avec la durée des branches (AIT ALLAOUA 2024).

Soit X_a la position d'une lignée au début d'une branche et X_b sa position à la fin, séparées par un temps t . Le modèle BD suppose :

$$X_b | X_a \sim \mathcal{N}(X_a, \sigma^2 t)$$

où σ^2 est la variance spatiale. Ce processus est isotrope et sans biais, ce qui signifie que le mouvement est équiprobable dans toutes les directions (Lemey et al. 2010)




Figure 3: **Illustration du modèle de diffusion brownienne (BD).** (A) Exemple de trajectoires simulées pour plusieurs lignées à partir d'un ancêtre commun (MRCA), représentant un mouvement brownien homogène dans une dimension spatiale au cours du temps. (B) Distribution de probabilité de la position finale le long de la dimension X pour l'ensemble des lignées. Les lignes verticales pointillées indiquent la position finale de chaque lignée.

3.1.2.2 Relaxed Random Walk (RRW)

Le modèle RRW est une extension du modèle BD qui autorise des vitesses de diffusion variables d'une branche à l'autre (Lemey et al. 2010; AIT ALLAOUA 2024). À chaque branche b est associé un scalaire de taux ϕ_b tiré

d'une loi Gamma ou log-normale, ce qui permet de modéliser une hétérogénéité de dispersion liée à des facteurs biologiques ou environnementaux (fig. 4).

La distribution branche-spécifique devient alors :

$$X_b \mid X_a, \phi_b \sim \mathcal{N}(X_a, \Sigma \phi_b t)$$

où t est la longueur temporelle de la branche.

Le RRW permet de capturer des patrons de dispersion hétérogènes et de mieux ajuster les données empiriques, souvent avec une réduction des intervalles de densité a posteriori (HPD) des positions ancestrales (Lemey et al. 2010). Il est particulièrement adapté aux données présentant une sur-dispersion des vitesses de déplacement.




Figure 4: **Relaxed Random Walk (RRW) : hétérogénéité des vitesses le long de l'arbre.** (A) Exemple de diffusion continue sur un arbre où chaque branche possède son propre *scalaire de diffusion* ϕ (valeurs annotées) - tiré d'une distribution (log-normale ici) - plus ϕ est grand, plus la trajectoire « s'étale ». Le temps est porté sur l'axe vertical ; la racine A est en rouge, les feuilles $B-E$ en couleurs. (B) Distribution marginale de la position X attendue à chaque feuille sous le RRW : pour une feuille donnée, la variance est la somme des variances le long du chemin racine→feuille, d'où des courbes plus ou moins larges selon l'accumulation des ϕ (Lemey et al. 2010).

3.1.3 Récapitulatif

- **IBD**: modèle discret en temps et en espace, biologiquement réaliste, variation génétique lié à la distance physique, inférence des paramètres

du modèle plus complexe.

- **BD** : modèle continu en temps et en espace, simpliste et homogène, avec variance $\propto t$.
- **RRW** : extension du modèle BD, variance branche-spécifique via ϕ , plus flexible et réaliste, couplé à des méthodes d'inférence bayésienne des paramètres du modèle moins complexe.

3.2 Méthodes d'inférence

3.2.1 Inférence bayésienne sous modèle RRW avec BEAST

Bayesian Evolutionary Analysis Sampling Trees « BEAST » (Suchard et al. 2018) est un logiciel d'inférence phylogénétique bayésienne. Il permet d'analyser des phylogénies datées, avec une horloge moléculaire stricte ou relâchée, et d'inférer des paramètres de diffusion spatiale en utilisant notamment le modèle *Relaxed Random Walk* (Lemey et al. 2010; AIT ALLAOUA 2024).

Dans le cadre de la phylogéographie, les coordonnées spatiales (latitude/longitude) des séquences sont traitées comme des caractères continus évoluant le long des branches de l'arbre.

En pratique, BEAST modélise l'évolution spatiale comme un processus de diffusion multivarié sur l'arbre phylogénétique. La variance de la position finale d'une branche de durée t est donnée par :

$$\Sigma \phi t$$

où Σ est la matrice de variance spatiale et ϕ le facteur de taux spécifique à la branche.

L'inférence est réalisée dans un cadre bayésien à l'aide d'algorithmes *Markov Chain Monte Carlo* (MCMC). Cette approche permet :

- d'estimer simultanément la phylogénie, les paramètres du modèle et les trajectoires spatiales ;
- de quantifier l'incertitude sur les positions ancestrales via des intervalles de densité a posteriori (HPD) ;
- de prendre en compte la variabilité des vitesses de dispersion le long de l'arbre.

3.2.1.1 Paramètres du modèle phylogénétique

L'inférence sous BEAST repose sur un ensemble de paramètres décrivant à la fois l'évolution des séquences et la dynamique spatiale des lignées. Dans notre configuration, ces paramètres incluent :

Coordonnées spatiales.

Les positions géographiques (latitude et longitude) sont modélisées comme des caractères continus évoluant le long de l'arbre phylogénétique selon le modèle *Relaxed Random Walk* décrit précédemment. Leur variance est fonction de la durée des branches et du facteur de taux ϕ propre à chacune.

Horloge moléculaire.

Une horloge moléculaire est utilisée pour relier la longueur des branches (en substitutions par site) au temps calendaire. Dans une horloge stricte, le taux est constant sur l'ensemble de l'arbre. Ici, nous utilisons une horloge relâchée non-corrélée (*Uncorrelated Relaxed Clock*), qui permet à chaque branche d'avoir un taux de substitution distinct, tiré d'une loi donnée (par ex. log-normale). Cela reflète l'hétérogénéité observée dans les vitesses d'évolution entre lignées.

Modèle de substitution.

L'évolution des séquences nucléotidiques est modélisée avec le modèle HKY (*Hasegawa–Kishino–Yano*), identique à celui employé lors des simulations. Ce modèle prend en compte :

- des fréquences de bases inégales ;
- un rapport de transitions/transversions κ distinct de 1.

Taux de mutation.

Le taux de substitution par site et par unité de temps est fixé à la valeur utilisée dans les simulations, afin d'assurer la comparabilité entre les données simulées et l'inférence.

Les autres paramètres libres du modèle (cf. ci-dessus) sont estimés conjointement avec la phylogénie et les trajectoires spatiales dans un cadre bayésien, en intégrant l'incertitude sur chacun d'entre eux.

3.2.2 Méthode de régression sous le modèle IBD

L'approche décrite par Rousset 1999 montre que, sous un modèle *Isolation by Distance* (IBD), il existe une relation linéaire entre la distance génétique a_r séparant deux individus et le logarithme de leur distance physique r :

$$a_r \approx \frac{\ln r}{4D\pi\sigma_{\text{IBD}}^2} + \text{constante} \quad (1)$$

où :

- σ_{IBD}^2 est le second moment de la distance de dispersion, c'est-à-dire la variance de la distribution des distances de déplacement par génération dans le cadre du modèle IBD¹;
- D est la densité d'individus dans la population (individus par unité de surface).

Dans ce cadre, le terme $4D\pi\sigma_{\text{IBD}}^2$ peut être estimé à partir de la pente m obtenue par régression linéaire de a_r sur $\ln r$:

$$4D\pi\sigma_{\text{IBD}}^2 \approx \frac{1}{m}. \quad (2)$$

Cette relation permet donc, en connaissant D , d'estimer σ_{IBD}^2 directement à partir des données empiriques de distances génétiques et géographiques.

3.2.2.1 Implémentation du IBD via genepop.

Dans ce travail, l'estimation de a_r et la régression associée sont effectuées à l'aide du logiciel **Genepop** (Rousset 2008). Cet outil calcule la statistique a_r (une mesure de différenciation génétique) pour chaque paire d'individus ou de populations, à partir de génotypes multilocus (Dans notre cas chaque position correspond à un locus). Les distances géographiques correspondantes sont fournies en entrée, et **Genepop** réalise la régression de a_r sur $\ln r$, renvoyant la pente m ainsi que des tests statistiques (par permutation) de la significativité de la relation. Cette approche permet ainsi d'obtenir une estimation de $4D\pi\sigma_{\text{IBD}}^2$ et, en connaissant D , de déduire σ_{IBD}^2 pour les données simulées.

3.2.3 L'estimation par le modèle BD non-phylogénétique (approche analytique)

La diffusion brownienne, en phylogéographie, modélise un mouvement aléatoire et continu dans un espace géographique homogène en temps et en espace. Cela implique un taux de diffusion constant sur l'ensemble des lignées et de l'arbre phylogénétique (Lemey et al. 2010). Cependant cette méthode est qualifiée de *non-phylogénétique* car elle ne modélise pas explicitement l'évolution des séquences le long d'un arbre (fig. 5). Ce modèle est pertinent pour décrire des déplacements réguliers, mais peut simplifier à l'excès des situations réelles où les vitesses de dispersion varient selon les lignées ou au cours du temps.

¹Ce paramètre ne doit pas être confondu avec la variance spatiale σ^2 utilisée dans les modèles de diffusion brownienne ou de *Relaxed Random Walk*, qui correspond à un processus continu dans le temps et peut avoir une interprétation différente.

Sous ce modèle, la position d'un individu sur un axe (par exemple l'axe x) suit une distribution normale :

$$x \sim \mathcal{N}(\bar{x}, \sigma^2 t)$$

où t est le temps séparant l'individu de l'ancêtre commun le plus récent.

L'estimation de σ^2 revient alors à calculer la variance des positions échantillonnées, divisée par le temps à l'ancêtre commun le plus récent $T_{MRC A}$:

$$\sigma^2 \approx \frac{\text{Var}(x)}{T_{MRC A}}$$

Bien que cette méthode soit qualifiée de *non-phylogénétique*, elle nécessite toutefois de connaître $T_{MRC A}$, qui est généralement estimé à partir d'une phylogénie reconstruite à partir des données génétiques.




Figure 5: **Illustration du modèle de diffusion brownienne non-phylogénétique.** (A) Simulation de trajectoires de lignées partant de l'ancêtre commun le plus récent (MRCA, en rouge) avec un taux de diffusion constant σ^2 . Les positions finales des quatre lignées (A–D) suivent un processus de diffusion isotrope et sans biais. (B) Distribution normale théorique $\mathcal{N}(0, \sigma^2 t)$ attendue pour les positions après un temps t , centrée sur le MRCA, avec les positions finales observées des lignées représentées par des traits verticaux colorés.

Cette approche suppose également, de façon simplificatrice, que toutes les observations de x sont indépendantes les unes des autres, une hypothèse

en réalité fausse car les individus sont liés par une phylogénie. Néanmoins, cette simplification permet une estimation rapide et directe de σ^2 à partir des données géographiques disponibles.

3.2.4 La méthode de régression par BD non-phylogénétique

Cette approche se repose sur la régression directe entre la distance géographique et la distance génétique entre paires d'individus. Les distances géographiques sont ici les distances euclidiennes physiques entre les positions des individus, tandis que les distances génétiques sont calculées à partir du modèle de Jukes and Cantor 1969.

La distance de Jukes–Cantor est une mesure de divergence génétique dérivée d'un modèle simple de substitution nucléotidique. Ce modèle suppose que :

- toutes les substitutions entre les quatre bases (A, T, G, C) sont également probables ;
- les fréquences à l'équilibre des bases sont égales ;
- les substitutions se produisent selon un processus de Poisson.

Si p est la proportion observée de sites différents entre deux séquences, la distance de Jukes–Cantor est donnée par :

$$d_{JC} = -\frac{3}{4} \ln \left(1 - \frac{4}{3}p \right)$$

Elle fournit ainsi une estimation du nombre attendu de substitutions par site, en corrigeant le biais dû aux substitutions multiples non observables directement.

Afin d'utiliser cette relation pour estimer un taux de diffusion, on suppose que la dynamique spatiale des individus suit un mouvement brownien dans un espace de dimension K . On cherche alors à estimer l'espérance de la distance euclidienne au carré entre deux observations issues de ce mouvement.

Soient deux vecteurs de coordonnées $X_1 = (X_{1,1}, \dots, X_{1,K})$ et $X_2 = (X_{2,1}, \dots, X_{2,K})$. On définit la distance euclidienne au carré comme :

$$D^2 = \sum_{i=1}^K (X_{1,i} - X_{2,i})^2$$

On cherche à calculer :

$$\mathbb{E}(D^2) = \mathbb{E} \left(\sum_{i=1}^K (X_{1,i} - X_{2,i})^2 \right) = \sum_{i=1}^K \mathbb{E} (X_{1,i}^2 + X_{2,i}^2 - 2X_{1,i}X_{2,i})$$

$$\begin{aligned}
&= \sum_{i=1}^K (\mathbb{E}(X_{1,i}^2) + \mathbb{E}(X_{2,i}^2) - 2\mathbb{E}(X_{1,i}X_{2,i})) \\
&= \sum_{i=1}^K (\text{Var}(X_{1,i}) + \mathbb{E}(X_{1,i})^2 + \text{Var}(X_{2,i}) + \mathbb{E}(X_{2,i})^2 - 2\text{Cov}(X_{1,i}, X_{2,i}) - 2\mathbb{E}(X_{1,i})\mathbb{E}(X_{2,i}))
\end{aligned}$$

On suppose que $X_{1,i}$ et $X_{2,i}$ sont indépendants (deux mouvements browniens indépendants), donc :

$$\text{Cov}(X_{1,i}, X_{2,i}) = 0 \quad \text{et} \quad \mathbb{E}(X_{1,i}) = \mathbb{E}(X_{2,i})$$

Ce qui simplifie l'expression à :

$$\mathbb{E}(D^2) = \sum_{i=1}^K (\text{Var}(X_{1,i}) + \text{Var}(X_{2,i})) = 2 \sum_{i=1}^K \text{Var}(X_i)$$

Si les composantes X_i suivent un mouvement brownien unidimensionnel avec une variance $\sigma^2 T_{1,2}$, alors :

$$\mathbb{E}(D^2) = 2K\sigma^2 T_{1,2}$$

Or, on suppose que la distance génétique entre deux individus est proportionnelle au temps depuis leur plus récent ancêtre commun :

$$T_{1,2} = \frac{1}{2}\mathbb{E}(D_{G_{1,2}}) \Rightarrow \mathbb{E}(D^2) = K\sigma^2 \mathbb{E}(D_{G_{1,2}})$$

On en déduit un modèle de régression linéaire :

$$d_{1,2}^2 = \alpha \cdot d_{G_{1,2}} + \varepsilon_{1,2} \quad \text{avec} \quad \alpha = K\sigma^2$$

Ce modèle permet d'estimer α (et donc indirectement σ^2), à partir des distances génétiques (corrigées selon Jukes–Cantor) et géographiques observées, sans recours à un arbre phylogénétique.

Table 1: Résumé des modèles, type d'utilisation (simulation ou inférence) et outils/approches associés.

Modèle	Type d'utilisation	Outil / Approche
Isolation by Distance (IBD)	Simulation	GSpace
Isolation by Distance (IBD)	Inférence	Genepop
BD non-phylogénétique	Inférence	Régression
BD non-phylogénétique	Inférence	Analytique
BD phylogénétique (RRW)	Inférence	BEAST

3.3 Expériences

3.4 Objectifs de l'étude

L'objectif général de cette étude est d'évaluer la capacité de différentes méthodes à estimer le taux de diffusion spatiale à partir de données génétiques simulées.

Plus précisément, deux objectifs principaux sont poursuivis :

1. **Fiabilité de l'estimation sous RRW:** Déterminer si l'estimation du paramètre de diffusion σ^2 à partir d'un modèle *Relaxed Random Walk* (RRW) est fiable lorsque les données ont été simulées sous un modèle *Isolation by Distance* (IBD).
 - Sous-objectif : comparer les performances des différentes techniques d'inférence (bayésienne, régression, approche analytique).
2. **Impact de l'échantillonnage spatial:** Évaluer d'éventuels effets des patterns d'échantillonnage spatial sur l'estimation de σ^2 .

Dans le cadre du premier objectif, le paramètre de diffusion σ^2 étant défini globalement dans le modèle simulé, notre hypothèse est qu'il ne devrait pas être affecté par les conditions d'échantillonnage, notamment par le rayon d'échantillonnage. Néanmoins, le nombre de séquences échantillonnées pourrait influencer la puissance statistique et donc la précision des estimations.

Pour le second objectif, une seconde série d'expériences fait varier la *distance maximale de dispersion* autorisée entre individus. Cette distance, directement liée à la vitesse de diffusion dans le modèle simulé (plus elle est grande, plus les déplacements intergénérationnels possibles sont importants), devrait entraîner une augmentation systématique du taux de diffusion estimé. Comme précédemment, nous faisons l'hypothèse que cette relation ne dépend pas de la taille de l'échantillon.

Ces hypothèses sont testées à l'aide de jeux de simulations variés, analysés selon les différentes méthodes d'inférence présentées précédemment.

3.4.1 Effet du rayon d'échantillonnage sur les taux de diffusion

La qualité des estimations de taux de diffusion dépend potentiellement du schéma d'échantillonnage spatial appliqué aux individus. Nous avons étudié deux paramètres clés :

- le **rayon** r de la zone d'échantillonnage (distance maximale à partir du centre de la grille),
- le **nombre** n d'**individus échantillonnés** à l'intérieur de cette zone.

Pour cela, nous avons simulé plusieurs jeux de données à partir d'un même modèle de dispersion, puis échantillonné les individus selon un schéma circulaire centré sur la grille. Les taux de diffusion ont été estimés via les méthodes décrites dans le chapitre 3.2.

3.4.1.1 Effet de la zone échantillonnée

Le rayon r est systématiquement varié parmi les valeurs suivantes :

$$r \in \{10, 15, 20, 25, 30, 35, 40, 45, 50\}.$$

Pour chaque rayon, les individus ont été tirés uniformément dans la zone circulaire définie (fig. 6).




Figure 6: **Exemples de configurations d'échantillonnage circulaire pour trois rayons différents.** Les points rouges représentent 100 individus échantillonnés, le cercle bleu la limite du rayon et le point noir le centre.

3.4.1.2 Effet du nombre d'individus échantillonnés

Pour chaque rayon, le nombre d'individus n a été testé pour les valeurs suivantes :

$$n \in \{4, 20, 50\}.$$

3.4.2 Effet de la distance maximale de dispersion

Les événements de dispersion dans GSpace (i.e. dans le modèle IBD) sont gouvernés par les paramètres `Dispersal_Distribution`, `Disp_Dist_Max` et `Total_Emigration_Rate`. La distance physique parcourues par les individus impactant directement le taux de dispersion, nous avons testé plusieurs distances maximale de dispersion sur x et y :

$$\text{Disp_Dist_Max} \in \{(1, 1), (3, 3), (5, 5), (10, 10), (20, 20), (30, 30), (50, 50)\}$$

Les distances de dispersion sont tirées d'une distribution uniforme et la fréquence des événements de dispersion est à 90% et donc une probabilité de

$p = 0.1$ pour un individu de rester au sein du même dème d'une génération à l'autre.

De manière similaire à l'expérience précédente, le nombre d'individus échantillonnés n varie: $n \in \{4, 20, 50\}$ au sein d'une zone d'échantillonnage fixe $r = 50$.

3.5 Analyse statistique

Afin d'évaluer les relations entre les vitesses de dispersion estimées et les paramètres de simulation, une série de modèles linéaires a été ajustée pour chaque méthode d'inférence testée. Les estimations issues des différentes approches (BD - analytique, BD - régression, RRW - BEAST et IBD - régression) ont été utilisées comme variables dépendantes, tandis que le rayon d'échantillonnage (r) ou les distances maximales de dispersion jouaient le rôle de variable explicative selon l'expérience considérée.

Plus précisément, pour chaque condition expérimentale (nombre de séquences fixé), un modèle de régression linéaire de la forme :

$$\text{estimation} = \beta_0 + \beta_1 \cdot X + \varepsilon$$

a été ajusté par moindres carrés (méthode OLS), avec X représentant soit le rayon, soit la distance maximale de dispersion. L'ajustement a été réalisé à l'aide de la bibliothèque `statsmodels` en Python. Les p-valeurs associées au coefficient directeur β_1 ont permis d'évaluer la significativité statistique de la relation entre l'estimation de la vitesse de dispersion et le paramètre de simulation.

4 Résultats

4.1 Effet du rayon d'échantillonnage

4.1.1 Modèle: RRW | Méthode: BEAST

Les analyses montrent une augmentation nette de la vitesse de dispersion estimée par BEAST avec le rayon d'échantillonnage, et ce pour toutes les tailles d'échantillon testées. Cette tendance est particulièrement marquée pour les jeux de données à 50 séquences, avec des vitesses médianes passant d'environ 0.01 à près de 0.025 - soit un doublement - et des intervalles de confiance relativement larges. Pour 20 séquences, la pente est également positive, mais les estimations sont plus stables, avec une variabilité réduite. En revanche, pour $n = 4$, les vitesses restent très faibles et proches de zéro, bien qu'elles augmentent légèrement avec le rayon.




Figure 7: **Estimation de la vitesse de dispersion par BEAST** selon le rayon d'échantillonnage pour $n = 4, 20$ et 50 séquences.

Les modèles linéaires confirment la significativité statistique de la pente pour les trois tailles d'échantillon ($p < 0.05$). De plus, la pente croît avec la taille de l'échantillon, indiquant que le modèle est plus sensible aux variations du rayon lorsque davantage de séquences sont disponibles. Le signal devient ainsi plus fort et plus facilement détectable avec un échantillon plus grand.

Ces résultats vont à l'encontre de notre hypothèse initiale, qui prévoyait une pente nulle et l'absence d'impact de la taille de l'échantillon sur l'estimation du taux de diffusion. Au contraire, nous observons que la taille de l'échantillon influence directement la force du signal détecté et l'amplitude des estimations.

4.1.2 Modèle: BD | Méthode: Analytique

La méthode analytique basée sur le modèle de diffusion Brownienne présente une augmentation nette et quasi-linéaire de la vitesse de diffusion estimée en fonction du rayon d'échantillonnage, pour toutes les tailles d'échantillons. Cette tendance est accompagnée d'une variabilité plus marquée qu'avec BEAST, notamment pour les petits échantillons (zone d'incertitude étendue pour $n = 4$).

Les régressions linéaires indiquent une relation significative entre l'estimation et le rayon dans tous les cas, avec des pentes croissantes avec la taille de l'échantillon.

Ces résultats confirment une très forte sensibilité de cette méthode au rayon d'échantillonnage, avec des estimations systématiquement croissantes et des signaux d'autant plus nets que le nombre de séquences augmente. Cependant, cette approche peut être plus instable pour les faibles tailles d'échantillon.




Figure 8: **Estimation de la vitesse de diffusion via modèle BD.** selon le rayon d'échantillonnage pour $n = 4, 20$ et 50 séquences

4.1.3 Modèle: BD | Méthode: Régression




Figure 9: **Vitesses de diffusion estimées par régression - BD** en fonction du rayon d'échantillonnage, pour $n = 4, 20$ et 50 séquences. Défaut de visibilité, une figure comprenant les intervalles de confiance (très larges) est présenté en annexe.

Ce modèle s'appuie sur une régression linéaire directe entre les distances génétiques et les distances géographiques. Les vitesses estimées présentent une tendance croissante avec le rayon d'échantillonnage pour les trois tailles d'échantillons, mais avec une variabilité très importante, en particulier pour $n = 4$, où les estimations fluctuent fortement et atteignent parfois des valeurs aberrantes.

Les résultats statistiques montrent que la tendance n'est pas significative pour $n = 4$, suggérant que l'approche est instable pour des échantillons très restreints. En revanche, les régressions sont significatives pour $n = 20$ et $n = 50$, avec des pentes élevées et des relations linéaires bien établies. Cela montre que cette méthode devient fiable à partir d'une taille d'échantillon modérée, mais reste sensible au bruit dans les conditions d'échantillonnage réduites.

Comparée aux approches BEAST et analytique Brownienne, la régression BD non-phylogénétique est plus sensible au bruit, notamment pour les faibles tailles d'échantillon. Bien qu'elle capture la tendance globale, sa robustesse est moindre et nécessite un nombre de séquences suffisant pour produire des estimations fiables.

4.1.4 Modèle: IBD | Méthode: Régression




Figure 10: **Vitesses de diffusion estimées à partir de la pente des régressions IBD (Genepop)**, en fonction du rayon d'échantillonnage, pour $n = 4, 20$ et 50 séquences. Figure incluant les intervalles de confiance à 95% en annexe (fig. 19)

Les estimations issues de la méthode IBD sont globalement stables mais bruyantes, en particulier pour $n = 4$, où aucune tendance claire ne se dégage. Les résultats sont très dispersés et les intervalles de confiance (fig. 19 en annexe) particulièrement larges.

Les régressions linéaires montrent l'absence de relation significative pour les plus petits jeux de données. En revanche, les tendances positives deviennent significatives pour 20 et 50 séquences, indiquant une sensibilité croissante de la méthode à la structure spatiale avec la taille de l'échantillon.

Comparée aux autres approches, la méthode IBD est globalement moins

sensible au rayon d'échantillonnage et nécessite une taille d'échantillon importante pour fournir des signaux exploitables.

4.1.5 Résumé comparatif




Figure 11: Heatmap des modèle de régression linéaire des estimation contre la méthode d'estimation pour chaque taille d'échantillon $n = 4, 20, 50$

Selon notre hypothèse initiale, le taux de diffusion étant un paramètre global du processus simulé, son estimation ne devrait pas varier en fonction du rayon d'échantillonnage ni du nombre de séquences collectées. Or, les résultats montrent que cette attendu théorique n'est pas toujours respecté.

En pratique, toutes les méthodes testées présentent une certaine sensibilité au rayon d'échantillonnage, particulièrement marquée pour les faibles tailles d'échantillons. Les approches BEAST et analytique Brownienne détectent systématiquement une augmentation du taux estimé avec le rayon, ce qui reflète une dépendance structurelle au schéma d'échantillonnage. À l'inverse, la régression IBD ne montre un signal significatif qu'à partir de 20 séquences, tandis que la régression non-phylogénétique reste très instable pour $n = 4$.

Ces biais soulignent que, malgré un paramètre de diffusion constant, les estimations peuvent varier fortement selon la méthode et le design expérimental. Cela justifie la nécessité de calibrer soigneusement l'approche statistique employée, notamment en conditions de faible pouvoir d'échantillonnage.

4.2 Effet de la distance maximale de dispersion

Dans cette seconde série d'expériences, la distance maximale de dispersion autorisée entre individus à chaque génération a été progressivement augmentée. Étant donné que cette distance conditionne directement la vitesse de

diffusion dans le modèle simulé, notre hypothèse est qu'elle doit se traduire par une augmentation systématique du taux de diffusion estimé.

Nous évaluons ici la capacité de différentes méthodes (BEAST, IBD, BD analytique et régressions) à capturer cette dynamique. Conformément à notre hypothèse, on s'attend à ce que la distance maximale influence directement les estimations, mais que la **taille de l'échantillon** n'en modifie ni l'ampleur ni la significativité.

4.2.1 Modèle: RRW | Méthode: BEAST




Figure 12: **Estimation de la vitesse de dispersion par BEAST** selon la distance maximale de dispersion, pour $n = 4, 20$ et 50 séquences. Les bandes colorées représentent les intervalles inter-quantiles (2.5%-97.5%).

Les vitesses de diffusion estimées par BEAST montrent une décroissance nette avec l'augmentation de la distance maximale de dispersion, en particulier pour les petites distances. Ce comportement est visible pour toutes les tailles d'échantillons, bien qu'atténué pour les plus grandes distances. Les valeurs semblent se stabiliser au-delà de 20–30 unités.

Les résultats statistiques révèlent une pente significative uniquement pour $n = 20$ ($p = 0.0239$). Tandis que la régression n'est pas significative pour $n = 4$ sa tendance est positive. Ainsi, l'hypothèse d'une relation positive systématique entre distance maximale et vitesse estimée n'est que partiellement vérifiée, et dépend fortement de la taille de l'échantillon.

4.2.2 Modèle: BD | Méthode: Analytique

Les estimations de vitesse obtenues par la méthode analytique montrent des comportements contrastés selon la taille d'échantillon. Pour $n = 4$,




Figure 13: **Estimation de la vitesse de diffusion via modèle BD.** selon la distance maximale de dispersion, pour $n = 4, 20$ et 50 séquences

on observe une croissance des vitesses estimées avec la distance maximale de dispersion, en accord avec l'hypothèse d'augmentation des vitesses. Ce signal est confirmé par une pente positive dans le modèle linéaire, bien que non significative ($p = 0.201$).

En revanche, pour $n = 20$ et $n = 50$, les vitesses diminuent progressivement avec la distance maximale, jusqu'à atteindre une zone de stabilisation autour de 10–20 unités. Ces tendances visuelles ne sont pas détectées comme significatives dans les modèles linéaires ($p > 0.1$), mais elles suggèrent un comportement non linéaire ou un effet de seuil.

Enfin, la taille d'échantillon influence modérément la variabilité pour $n = 20$ et $n = 50$, ce qui est en accord avec l'hypothèse initiale.

4.2.3 Modèle: BD | Méthode: Régression

Les vitesses estimées via la régression suivant le modèle BD montrent une **très forte variabilité**, en particulier pour les petits échantillons ($n = 4$), où l'on observe des valeurs extrêmes et parfois négatives. Pour $n = 20$ et $n = 50$, les tendances sont plus lissées mais demeurent instables et bruitées.

Les résultats du modèle linéaire indiquent qu'aucune tendance n'est significative pour $n = 4$ et $n = 20$, tandis qu'une **pente décroissante significative** est détectée pour $n = 50$ ($p = 0.045$). Cela indique que, pour des échantillons suffisamment grands, la méthode semble capturer une relation négative entre distance maximale de dispersion et vitesse estimée, ce qui est contraire à l'hypothèse attendue.

Globalement, cette méthode se montre très sensible au bruit, avec des es-




Figure 14: **Vitesses de diffusion estimées par régression - BD**, selon la distance maximale de dispersion, pour $n = 4, 20$ et 50 séquences.

timations peu robustes, en particulier en dessous de 50 séquences. Elle est donc difficilement exploitable dans les régimes de faible échantillonnage, et ne respecte pas l'augmentation attendue du taux de diffusion.

4.2.4 Modèle: IBD | Méthode: Régression




Figure 15: **Vitesses de diffusion estimées à partir de la pente des régressions suivant un modèle IBD (Genepop)**, selon la distance maximale de dispersion, pour $n = 4, 20$ et 50 séquences.

La méthode IBD basée sur la régression présente des estimations particulièrement instables. Les courbes sont fortement bruitées et les vitesses estimées varient de manière non uniforme, voire contradictoire, notamment à $n = 50$ où on observe des inversions de tendance. À $n = 4$, les valeurs restent

proches de zéro mais très dispersées, tandis que les échantillons de taille intermédiaire ou grande ($n = 20, 50$) présentent des oscillations fortes et peu interprétables.

Les modèles linéaires ne révèlent aucune tendance significative pour aucune des tailles d'échantillons testées ($p > 0.05$ dans tous les cas), ce qui reflète bien le comportement erratique observé. Les intervalles de confiance très larges, visibles dans la figure 21 en annexe, confirment l'extrême variabilité de cette méthode.

En résumé, cette approche ne semble pas adaptée à l'analyse de l'effet de la distance maximale de dispersion. Elle échoue à restituer une tendance cohérente avec l'hypothèse attendue et reste trop sensible à la structure locale des distances et au bruit de fond génétique.

4.2.4.1 L'intervalle de précision de la régression suivant le modèle IBD




Figure 16: **Estimation de la vitesse de diffusion restreinte à un intervalle de distance maximale de dispersion < 20 , selon la méthode d'inférence utilisée.** Chaque courbe représente les médianes pour différentes tailles d'échantillons.

Plusieurs travaux (Leblois 2004; Rousset 1997) ont montré que l'inférence des vitesses de dispersion par régression de type isolation by distance (IBD) est sujette à un intervalle de précision. C'est-à-dire une plage de distances géographiques au sein de laquelle la pente estimée est la plus fiable - idéalement

entre σ et 20σ - car la relation linéaire n'est valide que sous les hypothèses de la distance géographique (r) en même temps ni très petites, ni très grandes. En dehors de cet intervalle, les relations entre distance génétique et distance géographique deviennent moins linéaires ou plus bruitées, réduisant la qualité des inférences.

Nos résultats confirment partiellement cette observation. En filtrant les données pour ne conserver que les cas où la distance maximale de dispersion est inférieure à 20, certaines méthodes révèlent des tendances linéaires significatives ou proches du seuil de significativité, ce qui n'était pas le cas sur l'ensemble des données.

La méthode BEAST présente des pentes significatives pour $n = 20$ et $n = 50$ avec une décroissance régulière de la vitesse estimée lorsque la distance maximale augmente, ce qui pourrait traduire une saturation du signal phylogénétique au-delà de cet intervalle. De même, la méthode de régression sous modèle BD montre une pente significative pour $n = 50$, malgré une forte variabilité. Enfin, bien que la méthode IBD ne présente pas de pente significative dans cet intervalle, sa performance semble plus stable et moins erratique qu'en dehors de cet intervalle, ce qui suggère une zone de fonctionnement relativement plus précise.

Ainsi, ces observations suggèrent que l'analyse par régression IBD (et plus largement les autres méthodes) bénéficie d'un intervalle de validité optimal, situé ici autour de distances maximales inférieures à 20 unités. Cela souligne l'importance d'un design expérimental approprié pour garantir la robustesse des inférences de vitesse de dispersion.

4.2.5 Résumé comparatif




Figure 17: **Heatmap des pentes de régression linéaire** (estimation $\sim$ max_disp_dist) pour chaque méthode et taille d'échantillon. Les étoiles indiquent les relations significatives ($p < 0,05$).

L'analyse de l'effet de la distance maximale de dispersion met en évidence des comportements contrastés selon les méthodes d'inférence utilisées.

Sur l'ensemble des distances testées, **aucune méthode** ne parvient à capturer une relation systématique - significativement - positive entre distance maximale et vitesse estimée, contrairement à l'hypothèse attendue. La majorité des modèles linéaires sont non significative, et les tendances sont souvent décroissantes ou instables, en particulier pour les petites tailles d'échantillons.

Cependant, en restreignant l'analyse aux cas où la distance maximale est inférieure à 20, un **intervalle de précision** émerge. Dans cette fenêtre, certaines méthodes - notamment **BEAST** (pour $n = 20$ et $n = 50$) et la **régression Brownienne** (pour $n = 50$) - révèlent des relations significatives mais tout de même négatives. De plus, la méthode **IBD par régression**, bien que globalement instable, devient plus cohérente dans cette plage, en accord avec la littérature sur les conditions optimales de l'inférence IBD.

Ces résultats suggèrent que la performance des méthodes dépend fortement du design d'échantillonnage, et que des fenêtres spécifiques de distances maximales (ici, < 20) peuvent améliorer la robustesse des estimations.

5 Discussion

L'objectif de cette étude était d'évaluer plusieurs méthodes d'inférence du taux de diffusion spatiale à partir de données génétiques simulées, en testant leur robustesse vis-à-vis du schéma d'échantillonnage. Deux paramètres ont été explorés : le rayon d'échantillonnage et la distance maximale de dispersion entre individus.

Concernant le rayon d'échantillonnage, les résultats révèlent une violation systématique de l'hypothèse d'invariance du taux de diffusion. Toutes les méthodes testées - BEAST, diffusion Brownienne (analytique ou par régression), et IBD - montrent une augmentation des vitesses estimées avec le rayon, en particulier à partir de 20 séquences. Cela met en évidence une dépendance des estimations à la configuration spatiale des échantillons, qui peut introduire un biais même lorsque le taux de diffusion simulé est constant.

Pour la distance maximale de dispersion, les résultats sont plus nuancés. Aucune tendance claire ne se dégage sur l'ensemble des données. Toutefois, en restreignant l'analyse aux cas où la distance maximale est inférieure à 20, certaines méthodes (notamment BEAST et la régression Brownienne) révèlent des tendances linéaires significatives. Cela suggère l'existence d'un intervalle de précision, déjà décrit dans la littérature pour le modèle IBD, où les estimations sont plus fiables.

En conclusion, cette étude souligne que les méthodes d'inférence du taux de diffusion sont sensibles aux choix d'échantillonnage, tant en termes d'échelle

spatiale que de nombre de séquences. Un design expérimental soigneusement calibré, tenant compte de la portée effective des méthodes et de leur zone de précision, est donc indispensable pour garantir des estimations robustes et interprétables en contexte phylogéographique.

6 Références

- AIT ALLAOUA, R. (2024). “Estimer la vitesse de dispersion de pathogènes à partir de la comparaison de séquences génétiques géo-référencées”. Projet bibliographique M1, Master Bioinformatique - université de Montpellier.
- Cavalli-Sforza, L. L. and A. W. Edwards (1967). “Phylogenetic analysis. Models and estimation procedures”. In: *Am. J. Hum. Genet.* 19.3 Pt 1, pp. 233–257.
- Dellicour, S. et al. (2018). “Phylogenetic assessment of intervention strategies for the West African Ebola virus outbreak”. In: *Nat. Commun.* 9. DOI: [10.1038/s41467-018-03763-2](https://doi.org/10.1038/s41467-018-03763-2).
- Jukes, T. H. and C. R. Cantor (1969). “Evolution of protein molecules”. In: *Mammalian Protein Metabolism*. Ed. by H. N. Munro. Vol. 3. New York: Academic Press, pp. 21–132.
- Leblois, R. (2004). *Inférence en génétique spatiale des populations vue par le prisme de la coalescence*. Université de Montpellier.
- Lemey, P. et al. (2010). “Phylogeography Takes a Relaxed Random Walk in Continuous Space and Time”. In: *Mol. Biol. Evol.* 27, pp. 1877–1885. DOI: [10.1093/molbev/msq074](https://doi.org/10.1093/molbev/msq074).
- Malécot, G. (1948). “Les mathématiques de l’hérédité”. In: *Paris: Masson*.
- Pybus, O. G. et al. (2012). “Unifying the spatial epidemiology and molecular evolution of emerging epidemics”. In: *Proc. Natl. Acad. Sci.* 109.37, pp. 15066–15071. DOI: [10.1073/pnas.1206598109](https://doi.org/10.1073/pnas.1206598109).
- Rousset, F. (Apr. 1997). “Genetic Differentiation and Estimation of Gene Flow from F-Statistics Under Isolation by Distance”. In: *Genetics* 145.4, pp. 1219–1228. DOI: [10.1093/genetics/145.4.1219](https://doi.org/10.1093/genetics/145.4.1219).
- (Jan. 1999). “Genetic differentiation between individuals”. In: *Journal of Evolutionary Biology* 13.1, pp. 58–62. ISSN: 1010-061X. DOI: [10.1046/j.1420-9101.2000.00137.x](https://doi.org/10.1046/j.1420-9101.2000.00137.x).
- (2004). *Genetic Structure and Selection in Subdivided Populations*. Princeton University Press.
- (2008). “genepop’007: a complete re-implementation of the genepop software for Windows and Linux”. In: *Molecular Ecology Resources* 8.1, pp. 103–106. DOI: <https://doi.org/10.1111/j.1471-8286.2007.01931.x>.
- Suchard, Marc A. et al. (2018). “Bayesian phylogenetic and phylodynamic data integration using BEAST 1.10”. In: *Virus Evolution* 4.1, vey016. DOI: [10.1093/ve/vey016](https://doi.org/10.1093/ve/vey016).
- Virgoulay, T., F. Rousset, and R. Leblois (2021). “GSpace: an exact coalescence simulator of recombining genomes under isolation by distance”. In: *Bioinformatics* 37.20, pp. 3673–3675. DOI: [10.1093/bioinformatics/btab261](https://doi.org/10.1093/bioinformatics/btab261).
- Wright, S. (1943). “Isolation by distance”. In: *Genetics*.

7 Annexe

Effet du rayon d'échantillonnage




Figure 18: fig. 9 incluant les intervalles de confiance à 95%




Figure 19: fig. 10 incluant les intervalles de confiance à 95%

Effet de la distance maximale de dispersion

Toutes les distances de dispersion maximales




Figure 20: fig. 13 incluant les intervalles de confiance à 95%




Figure 21: fig. 15 incluant les intervalles de confiance à 95%

les distances de dispersion maximales < 20




Figure 22: fig. 16c incluant les intervalles de confiance à 95%




Figure 23: fig. 16d incluant les intervalles de confiance à 95%